Segmentación y clasificación de patologías retinales en imágenes OCT mediante Deep Learning

Alexis Barniquez | Barbara Cerezo | Daniel Paniagua | Brian Salamone

Visión por Computadora II - CEIA - 2026

Contexto clínico

El problema

- Las enfermedades retinales (CNV, DME, Drusen) son causas principales de perdida de visión a nivel mundial
- La Tomografía de Coherencia Óptica (OCT) es el estándar de imagen para diagnostico oftalmológico
- Se requieren herramientas automatizadas que asistan al especialista en el diagnostico temprano

4 clases de patología

CNV
Neovascularización coroidea

DME
Edema macular diabético

DRUSEN
Depositos sub-retinales

NORMAL
Retina sana

Objetivo e hipótesis

Pregunta: ¿la segmentación semántica de capas retinales como preprocesamiento, mejora la clasificación automática de patologías en imágenes OCT?

Hipótesis

La información estructural extraída por un modelo de segmentación debería mejorar la capacidad del clasificador al proveer representaciones mas ricas de la anatomía retinal.

Enfoque experimental

1. Entrenar UNet++ para segmentar 8 capas retinales
2. Entrenar ResNet50 sobre imágenes OCT originales
3. Entrenar ResNet50 sobre mascaras de segmentación
4. Comparar ambos clasificadores aislando la variable de input

Datasets

Dataset de segmentación

Fuente: Kaggle - Retinal Layer Segmentation

Formato: archivos .npy (224 x 512 px, escala de grises)

9 clases: 8 capas retinales + fondo

Clase 0 (fondo) dominante; capas 1-7 balanceadas

Máscaras de segmentación píxel a píxel

Dataset de clasificación

Fuente: Kermany et al. (2018) - Cell

4 clases: CNV, DME, DRUSEN, NORMAL

Train: ~8,000 imágenes (WeightedRandomSampler)

Validación: 2,032 imágenes

Test: 4,015 imágenes (224 x 224 px)

Pipeline propuesto

Camino 1: clasificación directa

Imagen OCT
224 x 224 RGB

ResNet50
ImageNet pre-entrenadas

Predicción
Accuracy: 92%

Camino 2: segmentación + clasificación

Imagen OCT
Escala de grises

UNet++
ResNet34 encoder

Máscara
8 capas

ResNet50
ImageNet

Accuracy
72%

Mismo clasificador (ResNet50), diferente input. Esto aísla el efecto de la segmentación.

Modelo de segmentación: UNet++

Arquitectura y configuración

Modelo:	UNet++
Encoder:	ResNet34 (con pesos pre-entrenados / Imagenet)
Input:	1 canal, 224 x 512 px
Output:	8 clases de capas retinales
Loss:	CrossEntropyLoss
Optimizer:	Adam (lr = 1e-3)
Split:	80% train / 20% val (176/44 imgs)
Epochs:	50, batch size 8

Justificación técnica

¿Por qué UNet++ sobre U-Net?

Las conexiones densas anidadas mejoran la captura de detalles finos en capas retinales delgadas, críticas en OCT.

¿Por qué ResNet34 como encoder?

Balance entre capacidad de representación y costo computacional para imágenes médicas de un solo canal.

Resultados: segmentación

0.981
Dice (macro)

0.964
IoU (macro)

1.53
Hausdorff Dist. (px)

Dice y Hausdorff por capa retinal

ILM-RNFL	RNFL-GCL	GCL-IPL	IPL-INL	INL-OPL	OPL-ONL	ONL-IS	IS-OS
0.999	0.980	0.989	0.970	0.967	0.990	0.978	0.979

Convergencia del entrenamiento

Epoch	Train Loss	Val Loss	Mejora
1	0.9495	0.5684	-
10	0.0932	0.0854	85%
20	0.0530	0.0583	32%
30	0.0315	0.0354	39%
50	0.0192	0.0201	43%

Clasificación: 3 estrategias

Modelo 1: imágenes originales

Input: OCT RGB (224x224)

Replicar canal1 → 3 canales

ResNet50

Adam, lr = 1e-4

30 epochs, patience = 5

ColorJitter (+-0.2)

WeightedRandomSampler

Modelo 2: solo máscaras

Input: OCT RGB (224x224)

Resize (224,512)

U-Net SegmentadorEntrada: 1 canal

Resize (224,224)

ResNet50 1 → 3 canales

Adam, lr = 1e-4

20 epochs, patience = 5

WeightedRandomSampler

Modelo 3: híbrido 4-ch

Input: OCT RGB (224x224)

Resize (224,512)

U-Net SegmentadorEntrada: 1 canal

Resize (224,224)

ResNet50 1 → 4 canales

Adam, lr = 1e-4

20 epochs, patience = 5

WeightedRandomSampler

Resultados: clasificación comparativa

Mod. 1: originales

92%

Accuracy test

Mod. 2: solo máscaras

72%

Accuracy test

Mod. 3: híbrido 4-ch

92%

Accuracy test

El Modelo 3 (imagen + máscara) iguala al Modelo 1 (solo imagen). La segmentación no aporta información adicional.

F1-Score por clase

Clase	Mod. 1 (original)	Mod. 2 (máscara)	Mod. 3 (híbrido)	Delta 1 vs 2	Delta 1 vs 3
CNV	0.94	0.82	0.93	-0.12	-0.01
DME	0.94	0.78	0.93	-0.16	-0.01
DRUSEN	0.89	0.54	0.89	-0.35	0
NORMAL	0.91	0.71	0.92	-0.20	-0.01

Análisis: ¿por qué la segmentación no mejora?

1

Información de segmentación redundante

El Modelo 3 (imagen+mascara, 92%) iguala al Modelo 1 (solo imagen, 92%). La segmentación no agrega información que ResNet50 no extraiga ya de la imagen original.

2

Perdida de textura en máscaras puras

El Modelo 2 (solo máscaras, 72%) pierde textura, intensidad y contraste al reducir a etiquetas discretas 0-7. Información crítica para distinguir patologías.

3

DRUSEN: la clase más afectada (F1: 0.89 -> 0.54)

Los drusen son depósitos sub-retinales cuya detección depende de textura visual. El Mod. 3 híbrido recupera F1=0.89, confirmando que la imagen es la clave.

4

Discrepancia de dominios entre datasets

El modelo de segmentación fue entrenado con un dataset distinto al de clasificación. Diferencias en equipos OCT y resolución amplifican la degradación del Modelo 2.

Prototipo funcional: app demo

Funcionalidades

Segmentación interactiva

Visualización de las 8 capas retinales con overlay sobre la imagen OCT original

Clasificación comparativa

Predicción simultánea con ambos modelos, mostrando probabilidades por clase

Análisis visual

Barras de probabilidad, comparación lado a lado, overlay de segmentación

Carga de imágenes

El usuario puede subir imágenes OCT propias para obtener predicciones

Stack tecnológico

Framework: Streamlit

Segmentacion: PyTorch + SMP (UNet++)

Clasificación: PyTorch + torchvision (ResNet50)

Visualización: matplotlib + numpy

Peso modelos: ~125 MB total

Conclusiones

1. Modelo 1 (imágenes, 92%) y Modelo 3 (híbrido, 92%) superan al Modelo 2 (máscaras, 72%). La segmentación no mejora la clasificación.
2. El Modelo 3 híbrido (imagen+máscara) iguala al Modelo 1 (solo imagen): la segmentación es información redundante para ResNet50.
3. UNet++ con ResNet34 logra segmentación precisa (Dice=0.98, IoU=0.96), validando su utilidad como herramienta independiente.
4. DRUSEN es la clase mas sensible a la perdida de textura (F1: 0.89 -> 0.54 con máscaras). El híbrido lo recupera (F1=0.89).
5. La discrepancia de dominios entre datasets de segmentación y clasificación amplifica la degradación del Modelo 2.
6. La segmentación aporta valor clínico como herramienta de interpretabilidad, complementando al clasificador.
7. La app demo demuestra la factibilidad de un sistema de apoyo al diagnostico oftalmológico con DL.

¡Gracias!

¿Preguntas?

Alexis Barniquez | Barbara Cerezo | Daniel Paniagua | Brian Salamone

Visión por Computadora II - CEIA - 2026